



**ECOLE MAROCAINE DES
SCIENCES DE L'INGENIEUR**
Membre de
HONORIS UNITED UNIVERSITIES

Cours de 1^{re} année de classe préparatoire

Initialisation à l'Intelligence Artificielle



2024-2025

Réaliser par :

Pr. Saïd Benlakhdar

Pr. Imane belhayane

Sommaire

Partie 1 : Introduction à l'Intelligence Artificielle et au Machine Learning

Chapitre 1 : Fondamentaux de l'IA

- 1.1. Définition et objectifs de l'IA
- 1.2. Histoire et évolutions majeures
- 1.3. Types d'IA : faible, forte et super-intelligence
- 1.4. Domaines d'application de l'IA

Chapitre 2 : Introduction au Machine Learning

- 2.1. Définition et caractéristiques du ML
- 2.2. Programmation traditionnelle vs ML
- 2.3. Types d'apprentissage : supervisé, non supervisé
 - 2.3.1. Problèmes de classification, régression, clustering, association
 - 2.3.2. Algorithmes courants : régression linéaire, logistique
 - 2.3.3. Évaluation des modèles (précision, rappel, F1-score, R²...)
- 2.4. Apprentissage par renforcement

Partie 2 : Apprentissage Profond, NLP et Vision par Ordinateur

Chapitre 3 : Introduction au Deep Learning

- 3.1. Qu'est-ce que le Deep Learning ?
 - 3.1.1. Qu'est-ce qu'un neurone biologique ?
- 3.2. Perceptron et perceptron multicouche (PMC)
- 3.3. Réseaux de neurones artificiels : architecture, couches, fonctions d'activation
- 3.4. Comparaison Machine Learning vs Deep Learning

Chapitre 4 : Réseaux Neuronaux Convolutifs (CNN)

- 4.1. Structure d'un CNN
- 4.2. Convolution, filtres, pooling
- 4.3. Exemple avec la base MNIST

Chapitre 5 : Réseaux de neurones récurrents (Recursive Neural Networks - RvNN)

- 5.1. RNN et traitement de séquences

Partie 3 : Traitement du Langage Naturel (NLP)

- 3.1. Introduction au NLP
- 3.2. Sous-domaines : NLU, NLG
- 3.3. Techniques de base du NLP (Tokenisation, lemmatisation, stemming)
- 3.4. Représentation vectorielle : Word2Vec

Partie 4 : Exercices et Applications

- 3. Série 1 : Questions de compréhension, cas pratiques (prédiction, classification, clustering...)
- 4. Série 2 : Exercices avancés sur perceptrons, réseaux de neurones

Partie 1 : Introduction à l'Intelligence Artificielle et au Machine Learning

Chapitre 1 : Fondamentaux de l'IA

1.1. Définition et objectifs de l'IA

Qu'est-ce que l'Intelligence Artificielle ?

Selon le pionnier de l'Intelligence Artificielle, John McCarthy, c'est « la science et l'ingénierie qui consistent à créer des machines intelligentes, en particulier des programmes informatiques intelligents ». L'intelligence artificielle est une méthode permettant à un ordinateur, un robot contrôlé par ordinateur ou un logiciel de penser de manière intelligente, de la même manière que les humains intelligents pensent. L'IA est réalisée en étudiant comment le cerveau humain fonctionne, comment les humains apprennent, prennent des décisions et travaillent lorsqu'ils tentent de résoudre un problème, puis en utilisant les résultats de cette étude comme base pour développer des logiciels et des systèmes intelligents.

Philosophie de l'IA


En exploitant la puissance des systèmes informatiques, la curiosité humaine a poussé l'homme à se demander : « Une machine peut-elle penser et se comporter comme un humain? » Ainsi, le développement de l'IA a commencé avec l'intention de créer une intelligence similaire dans les machines à celle que l'on trouve chez les humains et que nous considérons comme élevée.

Objectifs de l'IA

- Créer des systèmes experts : Des systèmes qui manifestent un comportement intelligent, apprennent, démontrent, expliquent et conseillent leurs utilisateurs.
- Implémenter l'intelligence humaine dans les machines : Créer des systèmes qui comprennent, pensent, apprennent et se comportent comme des humains.

De quoi s'agit-il ?

Le développement de systèmes informatiques capables d'effectuer des tâches **qui nécessitent normalement l'intelligence humaine**, comme la prise de décision, la détection d'objets, la résolution de problèmes complexes, etc.



1.2.Histoire et évolutions majeures

Voici l'histoire de l'IA au cours du 20^e siècle :

Année	Événement marquant / Innovation
1923	Écrite en 1920, <i>R.U.R.</i> est jouée pour la première fois au Théâtre national de Prague le 25 janvier 1921, puis à New York dès 1922. C'est dans cette œuvre que Karel Čapek a utilisé le mot "robot" pour la première fois.
1943	Les bases des réseaux neuronaux sont posées.
1945	Isaac Asimov, ancien élève de l'Université de Columbia, a inventé le terme "robotique".
1950	Alan Turing introduit le test de Turing pour l'évaluation de l'intelligence et publie <i>Computing Machinery and Intelligence</i> . Claude Shannon publie <i>Detailed Analysis of Chess Playing as a Search</i> .
1956	John McCarthy invente le terme "Intelligence Artificielle". Première démonstration d'un programme IA fonctionnant à l'Université Carnegie Mellon.
1958	John McCarthy invente le langage de programmation LISP pour l'IA.
1964	La dissertation de Danny Bobrow au MIT montre que les ordinateurs peuvent comprendre le langage naturel suffisamment bien pour résoudre correctement des problèmes d'algèbre sous forme de mots.
1965	Joseph Weizenbaum au MIT crée ELIZA, un programme interactif qui mène un dialogue en anglais.
1969	Les scientifiques de Stanford Research Institute développent Shakey, un robot équipé de locomotion, de perception et de résolution de problèmes.
1973	Le groupe Assembly Robotics de l'Université d'Édimbourg construit Freddy, le célèbre robot écossais, capable d'utiliser la vision pour localiser et assembler des modèles.
1973	Le premier véhicule autonome contrôlé par ordinateur, le Stanford Cart, a été construit.


1985	Harold Cohen crée et présente le programme de dessin, Aaron.
1990	Progrès majeurs dans tous les domaines de l'IA : • Démonstrations significatives dans l'apprentissage automatique • Raisonnement basé sur des cas • Planification multi-agents • Planification • Extraction de données, Web Crawler • Compréhension et traduction du langage naturel • Vision, réalité virtuelle • Jeux
2000	Les robots interactifs de compagnie deviennent disponibles commercialement. Le MIT présente Kismet, un robot avec un visage qui exprime des émotions. Le robot Nomad explore les régions éloignées de l'Antarctique et localise des météorites.

1.3.Types d'IA : faible, forte et super-intelligence

1.Intelligence artificielle étroite

2. Intelligence artificielle générale

3. Super intelligence artificielle



1.3.1. Intelligence artificielle étroite (faible)

L'intelligence artificielle que nous avons réussi à concevoir à ce jour est principalement orientée vers un but précis, c'est-à-dire qu'elle est conçue pour accomplir des tâches spécifiques et uniques, comme la reconnaissance faciale, la reconnaissance vocale, la conduite autonome d'un véhicule ou la recherche sur Internet. Ces systèmes sont extrêmement performants pour les fonctions pour lesquelles ils ont été programmés, mais leur intelligence est limitée à ces tâches et n'étend pas au-delà. Par exemple, Siri, l'assistant vocal d'Apple, n'est pas une machine consciente capable de comprendre ou d'interagir de manière autonome. Ce qu'il fait, c'est traiter des commandes vocales, les analyser, les interpréter et les transformer en requêtes pour un moteur de recherche comme Google, afin de renvoyer des résultats pertinents, sans jamais posséder de véritable compréhension ou conscience.

Exemples :

- + Siri d'Apple, Alexa d'Amazon, Cortana de Microsoft et autres assistants virtuels.
- + Logiciels de reconnaissance d'images et de visages.
- + Outils de cartographie et de prédiction des maladies.
- + Robots de fabrication et drones.
- + Filtres anti-spam pour les courriels / outils de surveillance des médias sociaux pour les contenus dangereux.
- + Recommandations de contenu de divertissement ou de marketing basées sur le comportement de visionnage, d'écoute ou d'achat.
- + Voitures à conduite autonome.

1.3.2. Intelligence artificielle générale (IA forte ou IA profonde)

L'IA pourrait un jour atteindre un stade où les machines seraient capables de penser et de prendre des décisions de manière similaire aux humains. Ce concept repose sur l'idée d'une intelligence artificielle générale, capable d'imiter l'intelligence humaine, d'apprendre et d'appliquer ses connaissances pour résoudre une grande variété de problèmes. À ce niveau, l'IA serait capable de penser, comprendre et agir de manière indiscernable d'un être humain dans une situation donnée. Cependant, les chercheurs et scientifiques spécialisés dans ce domaine n'ont pas encore réussi à développer ce type d'IA forte. Pour y parvenir, ils doivent trouver un moyen de rendre les machines conscientes, en leur programmant un ensemble complet de capacités cognitives.

1.3.3. Super Intelligence artificielle (ASI)

L'Intelligence Artificielle Super intelligente (ASI) désigne un stade où les capacités des ordinateurs surpassent celles des êtres humains. Contrairement aux systèmes d'IA actuels qui imitent ou comprennent l'intelligence humaine, l'ASI représente un point où les machines deviennent conscientes d'elles-mêmes, dépassant ainsi l'intelligence et les aptitudes humaines. Dotée d'une mémoire supérieure et d'une capacité de traitement des données et des stimuli bien plus rapide, l'ASI permettrait des prises de décision et des résolutions de problèmes bien plus performantes que celles des humains. Totalement autonomes et capables de s'auto-apprendre, ces systèmes n'existent cependant pas encore à l'heure actuelle.

1.4. Domaines d'application de l'IA

L'IA a été dominante dans divers domaines tels que :

Jeux vidéo

L'IA joue un rôle crucial dans les jeux stratégiques tels que les échecs, le poker, le morpion, etc., où la machine peut envisager un grand nombre de positions possibles en fonction des connaissances heuristiques.

Traitement du langage naturel

Il est possible d'interagir avec l'ordinateur qui comprend le langage naturel parlé par les humains.

Systèmes experts

Il existe certaines applications qui intègrent la machine, les logiciels et des informations spécifiques pour offrir du raisonnement et des conseils. Elles fournissent des explications et des recommandations aux utilisateurs.

Systèmes de vision

Ces systèmes comprennent, interprètent et saisissent les entrées visuelles sur l'ordinateur. Par exemple :

- ✚ Un avion espion prend des photographies qui sont utilisées pour déterminer des informations spatiales ou pour créer des cartes des zones.
- ✚ Les médecins utilisent des systèmes experts cliniques pour diagnostiquer les patients.
- ✚ La police utilise des logiciels informatiques capables de reconnaître le visage d'un criminel à partir du portrait stocké réalisé par un artiste médico-légal.



Diagnostic Médicale



Voiture autonome



Filtrage du Spam



Reconnaissance d'image



Trading en bourse



Recommandation produit



Reconnaissance vocale




Traduction automatique

Chapitre 2 : Introduction au Machine Learning

2.1. Définition et caractéristiques du ML

C'est quoi le Machine Learning ?



Machine Learning:
"The field of study that gives computers the ability to learn without being explicitly programmed."

❑ DÉFINITION 1:



Le **Machine Learning** consiste à laisser l'ordinateur **apprendre** quel calcul effectuer, plutôt que de lui donner ce calcul (c'est-à-dire le programmer de façon explicite). **[Arthur Samuel 1959]**

Le Machine Learning (ou apprentissage automatique) est une forme d'intelligence artificielle qui permet aux machines d'apprendre et d'effectuer des tâches sans qu'elles aient besoin d'être explicitement programmées pour chaque tâche spécifique. Il repose sur l'idée que les machines peuvent tirer des enseignements de données, identifier des modèles et améliorer leurs performances avec le temps. Voici une explication des trois caractéristiques du Machine Learning :

1. **Apprend la relation entre les données :** Le Machine Learning permet à une machine d'analyser un ensemble de données et de comprendre les relations ou les patterns qui existent entre ces données. Par exemple, si la machine reçoit des données sur le comportement des consommateurs, elle peut apprendre à identifier des tendances ou des corrélations telles que les facteurs qui influencent les achats.
2. **Peut prédire des événements pour d'autres données :** Une fois que la machine a appris à partir d'un ensemble de données, elle peut utiliser ce qu'elle a appris pour faire des prédictions sur de nouvelles données qu'elle n'a jamais vues. Par exemple, après avoir analysé des historiques de ventes, le système pourrait prédire le volume de ventes futur en fonction de variables comme la saison, les promotions ou les tendances passées.
3. **Améliorer les performances par rapport à l'expérience :** Le Machine Learning permet aux machines d'améliorer leurs performances à mesure qu'elles traitent de nouvelles données. Chaque nouvelle donnée ou expérience fournit à l'algorithme plus

d'informations, ce qui lui permet de devenir plus précis et efficace au fil du temps en ajustant ses modèles en fonction des erreurs passées ou des nouvelles observations.

Le Machine Learning est un champ d'étude de l'intelligence artificielle qui se fonde sur des approches statistiques pour donner aux ordinateurs la capacité d'apprendre à partir de données.

- ✚ Apprendre aux machines en leur fournissant des données et en les laissant apprendre par elles-mêmes sans aucune intervention humaine.
- ✚ L'apprentissage automatique utilise des méthodes d'exploration de données et des algorithmes pour construire des modèles sur la logique derrière les données qui prédisent les résultats futurs. Les algorithmes sont basés sur les mathématiques et les langages de programmation.

Deep Learning ((apprentissage profond))

Le Deep Learning est un sous domaine du Machine Learning qui utilise des algorithmes conçus pour **fonctionner de façon similaire au réseau de neurones d'un cerveau humain**.

- Inspiré par le cerveau humain, qui se compose de milliards de neurones.
- Méthode la plus proche de l'intelligence humaine.


2.2. Programmation traditionnelle vs Machine Learning

La différence principale entre la programmation traditionnelle et le Machine Learning (ML) réside dans la manière dont un programme apprend à résoudre des problèmes.

1.1. Programmation Traditionnelle

Dans la programmation traditionnelle (ou classique), un programmeur écrit explicitement des règles et instructions pour résoudre un problème spécifique. Ces règles sont basées sur des algorithmes déterministes et suivent une logique précise, qui ne change pas une fois codée.



- **Exemple** : Si l'on souhaite qu'un programme additionne deux nombres, on va simplement écrire : $\text{somme} = a + b$. Il n'y a pas de variation ni d'apprentissage, c'est un processus direct et statique.



1.2. Machine Learning (ML)

Le Machine Learning (Apprentissage Automatique), en revanche, consiste à apprendre à partir de données. Plutôt que d'écrire des règles explicites, on entraîne un modèle en lui fournissant des données d'exemples. Ce modèle apprend à faire des prédictions ou à prendre des décisions en identifiant des patterns ou des relations dans les données.

- **Exemple** : Dans un problème de classification, au lieu d'écrire une règle précise, comme dans un programme classique (ex : "si âge > 50, alors maladie X"), le programme ML apprend à partir d'un grand nombre de données d'exemples pour comprendre comment ces caractéristiques se lient aux résultats.



Programmation classique	Machine Learning
Un programme informatique sans IA peut répondre aux questions spécifiques qu'il est censé résoudre.	Un programme informatique avec IA peut répondre aux questions générales qu'il est censé résoudre.
La modification du programme entraîne un changement dans sa structure.	Les programmes IA peuvent absorber de nouvelles modifications en assemblant des morceaux d'informations hautement indépendants. Ainsi, vous pouvez modifier même un petit détail d'information du programme sans affecter sa structure.
La modification n'est pas rapide et facile. Elle peut entraîner des effets négatifs sur le programme.	Modification de programme rapide et facile.

Exemples :

Parmi les problèmes suivants, lesquels se prêtent bien à être traités par le machine Learning ?

- Déterminer l'horaire optimal pour poster un contenu sur une page web.
- Déterminer le chemin le plus court entre deux nœuds dans un graphe.
- Prédire le nombre de vélos à mettre en location à chaque station d'un système de location de vélos.
- Évaluer le prix qu'un tableau pourra atteindre lors d'une vente aux enchères.
- Débruiter un signal radio.


❑ Exemple : prédiction de la pluie

- ✓ On n'a pas de formule toute faite à donner à l'ordinateur pour qu'il nous donne une estimation si la pluie va tomber ou non.
- ✓ On connaît les circonstances qui accompagnent généralement la pluie : la présence de nuages, la force du vent, le taux d'humidité...
- ✓ Le modèle s'entraîne sur les données. À la fin de son apprentissage, si on lui présente de nouvelles données météo, il sera capable de prédire s'il va pleuvoir ou pas.



❑ DÉFINITION 2 :

“On dit qu’un programme informatique apprend de l’expérience E en référence à une certaine classe de tâches T et une mesure de performance P, si sa performance aux tâches de T, mesurée par P, s’améliore avec l’expérience E.”---[Tom Mitchell, 1997]



- ✓ **Tâche T** : la tâche à traiter par le système
- ✓ **Performance P** : pour évaluer le système appris
- ✓ **Expérience E** : Training Data pour former le Système d'apprentissage

❑ Exemple 1 : Déterminer le prix de maison

Tâche T : prédire le prix d’une maison en fonction des caractéristiques (ex : sa surface).

Performance P : précision élevée des prix des maisons (accurate prices)

Expérience E : un Data set de maisons avec leurs prix.



❑ Exemple 2 : Spam filtering

Tâche T : identifier si un Email est un spam ou non.


Performance P : % des email spam filtré et % des email non-spam qui ont été mal filtré.

Expérience E : ensemble des emails ""labelisées"" par les utilisateurs.




2.3.Types d'apprentissage : supervisé, non supervisé, par renforcement

❑ 3 approches de machine Learning :




2.3.1. Apprentissage Supervisé

Le terme "supervisé" désigne l'action de surveiller et de diriger la réalisation d'un travail, d'un projet ou d'une opération. Il utilise des données de formation étiquetées et une collection d'échantillons de formation pour estimer une fonction.




- ✚ L'approche de l'apprentissage supervisé (Supervised Learning) en ML consiste à utiliser des jeux de données étiquetés qui entraînent des algorithmes pour classer les données ou prédire des résultats avec précision.
- ✚ L'objectif de l'apprentissage supervisé est d'apprendre une fonction qui, à partir d'un échantillon de données et des résultats souhaités, se rapproche le mieux de la relation entre entrée et sortie observable dans les données.

- ✚ Par exemple, disons que nous formons un algorithme de reconnaissance d'images pour distinguer les chats des chiens.
- ✚ Chaque point de données d'apprentissage sera une paire constituée d'une image (données d'apprentissage) et de l'étiquette spécifiant s'il s'agit d'un chat ou d'un chien.
- ✚ 2.3.2. Apprentissage non supervisé
- ✚ L'apprentissage non supervisé est un type d'apprentissage automatique dans lequel les données d'apprentissage sont fournies au système sans étiquettes ou valeurs pré-assignées.



- ✚ L'approche de l'apprentissage non supervisé (**Unsupervised Learning**) consiste à ne disposer que de données d'entrée (X) et pas de variables de sortie correspondantes.
- ✚ On l'appelle apprentissage non supervisé car, contrairement à l'apprentissage supervisé, il n'y a pas de réponse correcte ni d'enseignant. Les algorithmes sont laissés à leurs propres mécanismes pour découvrir et présenter la structure intéressante des données.
- ✚ L'objectif de l'apprentissage non supervisé est de modéliser la structure ou la distribution sous-jacente dans les données afin d'en apprendre davantage sur les données.
- ✚ Par exemple, un ensemble de données qui contient les préférences d'achat des utilisateurs du e-commerce. Les utilisateurs formeront probablement des groupes qui se comportent de manière similaire, et ils peuvent avoir un comportement d'achat similaire.


Apprentissage supervisé vs apprentissage non supervisé



Construction d'un modèle d'apprentissage supervisé

Il fonctionne en 4 étapes :

1. Importer les données (Dataset)
2. Créer un modèle
3. Calculer la fonction coût
4. Développer un algorithme d'apprentissage (algorithme de minimisation, par exemple : méthode des moindres carrés, descente de gradient)



Exercice :

- 1) Je veux écrire un programme qui utilise la fréquence des mots « science », « public », « accès », « université », « gouvernement », « financer », « éducation », « budget », « justice » et « loi » pour déterminer si un article traite ou non de politique scientifique. J'ai commencé par annoter un millier d'articles selon leur sujet. Quel genre de problème d'apprentissage automatique doit-je résoudre ?
- 2) Je dispose de 10 000 articles de journaux que je souhaite classer par leur thématique.

Dois-je utiliser un algorithme supervisé ou non supervisé ?

- 3) Je gère un outil qui permet d'organiser les liens HTML qui ont été sauvegardés. Je souhaite suggérer des catégories auxquelles affecter un nouveau lien, en fonction des catégories déjà définies par l'ensemble des utilisateurs du service. Quel type d'algorithme d'apprentissage dois-je utiliser ?

- 4) Je veux examiner mes spams pour déterminer s'il existe des sous-types de spams. Quel type d'algorithme d'apprentissage dois-je utiliser ?


2.3.1. Problèmes de classification, régression, clustering, association

Il existe deux grandes catégories d'apprentissage supervisé :

Les problèmes de régression

Les problèmes de régression correspondent aux situations dans lesquelles la machine doit prédire la valeur d'une variable **quantitative** (variable continue).

- Un problème de régression avec plusieurs variables d'entrée est appelé un problème de **régression multiple**
- **Exemples :**




- ✓ Prédire le prix de l'immobilier
- ✓ Prédire la consommation électrique
- ✓ Prédire la durée de vie d'un patient

La classification

La classification correspond aux situations dans lesquelles la machine doit prédire la valeur d'une **variable qualitative** (variable discrète). Autrement dit, la machine doit classer ce qu'on lui donne dans des classes.

- Un problème de classification peut être **binaire** (deux classes) ou **multi-class** (plus de deux classes).
- **Exemples :**
 - ✓ Email Spam / non Spam
 - ✓ Cancer / non Cancer

Photo de Chat / Chien



Regression




What will be the temperature tomorrow?



Classification



Will it be hot or cold tomorrow?



Les catégories d'apprentissage non supervisé


Le clustering

Le Clustering ou Regroupement consiste à séparer ou à diviser un ensemble de données en un certain nombre de groupes, de sorte que les ensembles de données appartenant aux mêmes groupes se ressemblent davantage que ceux d'autres groupes.


- + Cette technique permet aux spécialistes du marketing digital d'adapter leurs contenus en fonction des audiences identifiées.
- + Le Clustering est **de la classification non supervisée** : pas de classes prédéfinies

Exemples :

- ✓ Segmentation du marché en fonction de l'emplacement, des niveaux de revenus, de l'âge des acheteurs ou de n'importe quelle autre variable.




Clustering Vs Classification



**Regroupements
clustering**

Le regroupement (ou *clustering*) permet d'identifier des groupes d'individus au sein d'un jeu de données.



**Classifications
catégorisations**

La classification ou catégorisation permet d'attribuer des individus à des groupes déjà définis.

L'association

L'association consiste à découvrir des relations intéressantes entre des variables dans de grandes bases de données.

Ces méthodes sont souvent utilisées pour l'analyse du panier de consommation, qui permet aux compagnies de comprendre la relation entre l'achat de différents produits. Cela permet d'établir une relation de la forme : « Les individus qui achètent le produit X ont également tendance à acheter le produit Y ».

Exemples :

- ✓ Les personnes qui achètent une nouvelle maison ont aussi tendance à acheter de nouveaux meubles
- ✓ Si 15 clients ayant acheté un nouveau téléphone ont également commandé un casque, les algorithmes recommandent un casque à tous les clients qui mettent un téléphone dans leur panier



2.3.2. Algorithmes courants : régression linéaire, logistique, k-means, etc.

Apprentissage supervisé : La régression linéaire simple

Objectif d'une analyse de régression simple

Une fois la représentation graphique effectuée, il est facile de soupçonner l'existence d'une certaine relation entre les deux variables (caractères étudiés). Il faut maintenant chercher à exprimer cette relation à l'aide d'une équation mathématique.

Modèle de régression linéaire simple

$$Y = a + bX + \varepsilon$$

L'équation estimée de la régression linéaire simple (droite de la régression estimée, modèle empirique) peut être utilisée pour une estimation ponctuelle de la valeur moyenne de y pour une valeur particulière de x ou pour prévoir la valeur ponctuelle de y associée à une valeur particulière de x

$$\hat{Y} = \hat{a} + \hat{b}X$$

y : Variable dépendante ou expliquée.

$\hat{y}$: valeur de prévision de y pour une valeur x , ou moyenne de y estimée pour une valeur de x .

x : Variable indépendante ou explicative.

La méthode des moindres carrés

- Idée de base : cette méthode essaie de construire une droite de régression empirique qui minimise la somme des carrés des distances verticales entre cette droite et chacun des points observés.

$$\min \sum (y_i - \hat{y}_i)^2$$

y_i : valeur observée de la variable dépendante pour la $i^{\text{ème}}$ observation.


$\hat{y}_i$: valeur estimée de la variable dépendante pour la $i^{\text{ème}}$ observation.

Exemple : Nuage de points ou diagramme de dispersion

Supposons que le nombre d'heures d'études nécessaires pour préparer l'examen final en Introduction à l'IA et le nombre de bonnes réponses obtenues par chaque étudiant sont donnés dans le tableau suivant :

Heures d'étude (X)	5	8	6	9	10	8	5	4	10	4	10	7	9
Bonne réponse (Y)	5	8	7	9	10	7	4	4	8	2	9	6	8

Tracer le nuage de points ou le diagramme de dispersion des données présentées ci-dessus.



Principes de la méthode des moindres carrés ...

Les estimations ponctuelles des paramètres de la droite de régression obtenues par la méthode des moindres carrés sont :

$$b_0 = \bar{y} - b_1 \cdot \bar{x} \quad b_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$b_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

Taille de l'échantillon

À partir des données ci-dessous, déterminez les estimations ponctuelles des paramètres de la droite de régression selon la méthode des moindres carrés :

y_i	x_i	$x_i y_i$	x_i^2
24	10	240	100
40	20	800	400
36	30	1080	900
45	40	1800	1600
55	50	2750	2500
$\bar{y} = \frac{\sum y_i}{5} = 40$	$\bar{x} = \frac{\sum x_i}{5} = 30$	$\sum x_i y_i = 6670$	$\sum x_i^2 = 5500$

$$b_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{6670 - 5 \times 30 \times 40}{5500 - 5 \times (30)^2} = 0,67$$

$$b_0 = \bar{y} - b_1 \bar{x} = 40 - 0,67 \times 30 = 19,9$$

$$\hat{y} = 19,9 + 0,67x$$

Le coefficient de détermination (R^2) est une mesure qui permet de savoir à quel point notre modèle de régression linéaire est bon pour prédire les valeurs. En d'autres termes, il nous indique quelle proportion de la variation des valeurs qu'on essaie de prédire (la variable dépendante) est expliquée par les valeurs qu'on utilise pour faire la prédiction (la variable indépendante). R^2 est élevé, mieux notre modèle fonctionne.

✚ $R^2=1$ signifie que le modèle explique entièrement la variance de la variable dépendante (c'est-à-dire que les prédictions sont parfaites).

✚ $R^2=0$ signifie que le modèle ne parvient pas à expliquer la variance de la variable dépendante (c'est-à-dire que les prédictions ne sont pas meilleures que la moyenne de la variable dépendante).

Formule de calcul :

$$R^2 = 1 - \frac{S_R}{S_T}$$

Avec :

$$S_T = \sum (y_i - \bar{y})^2$$

et

$$S_R = \sum (y_i - \hat{y}_i)^2$$

2.3.3. Évaluation des modèles (précision, rappel, F1-score, R^2 ...)

L'évaluation des modèles est une étape cruciale en apprentissage automatique, car elle permet de mesurer la performance d'un modèle sur des données inédites. Pour les problèmes de classification, des métriques comme la précision mesurent la proportion de prédictions positives correctes, tandis que le rappel évalue la capacité du modèle à détecter toutes les instances positives. Le F1-score, qui est la moyenne harmonique de la précision et du rappel, offre un bon compromis entre ces deux métriques, surtout en cas de classes déséquilibrées. Pour les problèmes de régression, on utilise souvent le coefficient de détermination R^2 , qui indique la proportion de la variance expliquée par le modèle. Une bonne évaluation nécessite donc de choisir des métriques adaptées à la tâche, au contexte du problème et à la distribution des données.

Pour la classification :

Soient :

- **TP** = True Positives (vrais positifs)
- **FP** = False Positives (faux positifs)
- **FN** = False Negatives (faux négatifs)
- **TN** = True Negatives (vrais négatifs)

Précision (*Precision*) :

$$\text{Précision} = \frac{TP}{TP + FP}$$

Rappel (*Recall* ou Sensibilité) :

$$\text{Rappel} = \frac{TP}{TP + FN}$$

F1-score :

$$F1 = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

Exactitude (*Accuracy*) :

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

2.4. Apprentissage par renforcement

L'apprentissage par renforcement (Reinforcement Learning ou RL) est une branche de l'intelligence artificielle où un agent apprend à prendre des décisions en interagissant avec son environnement. Contrairement à d'autres types d'apprentissage, comme l'apprentissage supervisé, l'agent n'est pas explicitement guidé par des exemples étiquetés. Au lieu de cela, il reçoit des feedbacks sous forme de récompenses ou de pénalités en fonction des actions qu'il entreprend dans un environnement donné.

L'objectif de l'apprentissage par renforcement est d'amener l'agent à maximiser la somme des récompenses qu'il peut obtenir sur le long terme. L'agent explore et apprend progressivement les meilleures actions à prendre pour obtenir des récompenses positives, tout en évitant les actions qui entraînent des pénalités. Cette approche est largement utilisée dans des domaines comme la robotique, les jeux vidéo, la conduite autonome et bien d'autres encore.

Le processus d'apprentissage par renforcement repose sur trois éléments clés :

1. **L'agent** : l'entité qui prend les décisions.
2. **L'environnement** : tout ce avec quoi l'agent interagit.
3. **Les récompenses et pénalités** : les feedbacks que l'agent reçoit en fonction de ses actions, utilisés pour ajuster son comportement.

L'agent apprend au fil du temps en explorant différentes actions et en ajustant sa stratégie pour maximiser ses récompenses à long terme.


Exemples :

- ✓ apprendre à un robot à marcher en terrain difficile

La voiture autonome

▪ Exemple : Concevoir une voiture autonome

- ✓ **L'agent** est le logiciel qui conduit la voiture,
- ✓ **L'environnement** est l'espace virtuel dans lequel le véhicule évolue,
- ✓ **L'action** à un instant t , c'est la possibilité de changer de direction, de ralentir, d'accélérer etc...,
- ✓ **La récompense** est associée dans le cas où le véhicule circule correctement dans son environnement (à défaut, une **pénalité** est associée si le véhicule se heurte à un obstacle, par exemple),
- ✓ On parle de **politique** pour désigner le mécanisme qui lie les récompenses observées dans le passé et l'état du système à l'instant t



Partie 2 : Apprentissage Profond, NLP et Vision par Ordinateur

Chapitre 3 : Introduction au Deep Learning

3.1. C'est quoi le Deep Learning ?

Le Deep Learning, ou apprentissage profond est un sous-domaine avancé de l'apprentissage automatique (Machine Learning) qui repose sur l'utilisation de réseaux neuronaux artificiels composés de multiples couches hiérarchiques. Ces architectures sont inspirées du fonctionnement du cerveau humain, en particulier des neurones biologiques et cherchent à reproduire leur capacité à traiter, transmettre et interpréter l'information.

Dans un réseau neuronal profond, les couches successives de neurones permettent au modèle de transformer progressivement les données brutes (comme des images, du texte ou des signaux audio) en représentations de plus en plus abstraites et significatives. Par exemple, un réseau peut d'abord détecter des bords dans une image, puis des formes, puis des objets entiers, à mesure que les couches s'enchaînent.

Le Deep Learning se distingue par sa capacité à apprendre automatiquement à partir de grandes quantités de données, sans nécessiter une extraction manuelle de caractéristiques par un humain. À mesure que le modèle est exposé à davantage de données, il ajuste ses paramètres internes (les poids synaptiques des neurones artificiels) pour améliorer ses performances, ce qui permet une amélioration continue de la précision des prédictions.

Grâce à cette capacité d'apprentissage profond, ces modèles sont particulièrement efficaces dans des domaines complexes comme :

- ✚ **La vision par ordinateur (reconnaissance faciale, détection d'objets),**
- ✚ **Le traitement automatique du langage naturel (traduction, résumé automatique, assistants vocaux),**
- ✚ **La reconnaissance vocale,**
- ✚ **Et même la conduite autonome.**

Vocabulaire : Neurone Informatique




Fig.1. Neurone Biologique vs Neurone Artificiel

3.1.1. Qu'est-ce qu'un neurone biologique ?

Un neurone biologique reçoit des signaux électriques d'autres neurones en amont via des points d'entrées (x_0, x_1, x_2 et x_3). Ces signaux sont accumulés à l'intérieur du corps du neurone, et si la somme de ces signaux dépasse un certain seuil, le neurone s'active et envoie à son tour un signal à des neurones en aval.




Fig.2.Processus de Traitement de l'Information par un perceptron

3.2.Perceptron et perceptron multicouche (PMC)

Perceptron

Le perceptron est l'un des modèles les plus anciens et les plus simples des réseaux de neurones artificiels. Conçu à l'origine comme un classificateur binaire, il permet de déterminer si un élément appartient ou non à une classe donnée. Ce modèle de neurone artificiel fonctionne en recevant plusieurs signaux d'entrée, chacun étant pondéré par un coefficient (ou poids). Ces signaux pondérés sont ensuite additionnés, puis transformés mathématiquement à l'aide d'une fonction d'activation pour produire une sortie unique. Bien que basique, le perceptron est capable de réaliser des tâches de classification, et dans certaines extensions, des tâches de régression.




Fig.3. Problème de classification





Fig.4. Problème de régression

3.3. Réseaux de neurones artificiels : architecture, couches, fonctions d'activation

Fonction d'activation

Step function : aussi appelée fonction d'activation échelon unité ou de Heaviside



Perceptron : étude de cas

Problème : Nous disposons d'un système d'aide à la décision qui permet de décider si un véhicule peut traverser ou pas un pont. Soit $y=0$ pour véhicule peut traverser et $y=1$ pour véhicule ne peut pas traverser. Le système est basé sur un perceptron simple dont la fonction d'activation est une fonction à échelon, avec $\theta=0$ et dont les poids synaptiques sont :

$$w_0 = -47, w_1 = 2, w_2 = 1.$$

Erreur de décision du perceptron.


Véhicule	x1	x2	Y	Y_pred
Camion 1	20	8	1	1
Camion 2	15	20	1	1
Bus 1	16	10	0	0
Bus 2	15	5	1	0
Voiture 1	5	15	0	0
Voiture 2	16	6	1	0
Moto 1	2	20	0	0
Moto 2	6	16	1	0

- Influence des poids : exemple

Problème statement :

Supposons que vous voulez sortir prendre un café. La décision va dépendre de trois facteurs :

- Est-ce qu'il fait beau ?
- Est-ce qu'il y a un moyen de transport disponible ?
- Est-ce que le café a une terrasse ?



X1= Est ce qu'il fait beau? -> **W1**
 X2= Est ce qu'il y a un moyen de transport disponible? -> **W2**
 X3= Est ce que le café a une terrasse? -> **W3**

$W1=6, W2=2, W3=2$

Threshold=5

Il fait beau, il n'y a pas de moyen de transport et le café n'a pas de terrasse

$X1=1, X2=0, X3=0$

$\Rightarrow 6$
 $\Rightarrow 6 > 5$
 $\Rightarrow \text{Output} = 1$
 $\Rightarrow \text{Sortir au café}$

Apprentissage du perceptron simple

- ✚ L'apprentissage du perceptron simple a pour objectif la détermination des valeurs des poids synaptiques qui permettent de fournir la sortie (classe) $\hat{y}$ à partir des données d'apprentissage x_i .

- ✚ **Comment calculer l'erreur et mettre à jour les valeurs de poids ?**

- ✚ Calculer la prédiction $\hat{y}$ de l'entrée x_i et la comparer à la classe réelle.

$$\text{Erreur} = \text{Desired} - \text{Predicted}$$

- ✚ **La mise à jour des poids :**

$$w_i(\text{New}) = w_i(\text{Old}) + x_i \times \text{Erreur} \times \alpha$$

La constante α est appelée pas d'apprentissage ou taux d'apprentissage ; elle est souvent fixée à la valeur 0.1.

Le critère d'arrêt peut être le nombre maximal d'itérations ou bien une valeur d'erreur fixée au préalable.

4. Exercice :

Appliquez la règle de mise à jour des poids pour entraîner les données.

Problème : On ne connaît pas les valeurs correctes des poids.

x1	x2	y
2	0	1
0	3	0
3	0	0
1	1	1

On donne des valeurs aléatoirement : $w_0 = 0.5$, $w_1 = 0$, $w_2 = 0$.

- ✚ La fonction d'activation considérée est une fonction échelon avec $\theta = 0$ et le nombre des itérations est : $t_{\max} = 4$, Le taux d'apprentissage = 0.1.

- ✚ **Sigmoid function :** renvoie des valeurs dans l'intervalle (0,1), ce qui en fait une fonction idéale pour modéliser des probabilités




Fig.6. Fonction d'activation sigmoïde


ReLU function : abréviation de rectified linear activation function. Si l'entrée (x) est positive, la fonction ReLU renvoie simplement l'entrée ; si l'entrée est négative ou égale à zéro, elle renvoie zéro.




Fig.7. Fonction d'activation sigmoïde

Comment marche un réseau ?

Un réseau consiste en un certain nombre d'éléments simple mais hautement interconnectés appelés nœuds ou neurones. Ces neurones sont organisés en couches qui traitent l'information de manière dynamique quant aux entrées. La première couche est la couche d'entrée. La dernière couche est appelée par défaut la couche de sortie.




Fig.8. Architecture d'un réseau de neurones

Perceptron multicouche

- Le PMC est un modèle de réseau qui contient, à la différence de neurones formels (perceptron simple) qui n'ont que la couche d'entrée et celle de sortie, des couches cachées ayant pour fonction de faire des traitements intermédiaires pour une meilleure prédiction.
- Plus il y a de couches, plus le réseau est profond et le modèle devient riche. C'est du Deep Learning.






Fig.9. Perceptron multicouche

3. Qu'est ce qu'un réseau de neurones artificielle (RNA) ?



- Le réseau de neurones n'est en fait qu'un regroupement de composantes de base appelés neurones (**perceptrons**) qui sont interconnectés entre eux.
- Les neurones sont organisés en 3 types de couches :
 - La couche d'entrée** – input layer
 - La ou les couche(s) cachée(s)** – hidden layer(s)
 - La couche de sortie** – output layer

3.4. Machine Learning vs Deep Learning : Comprendre la différence



Quand utiliser le Deep Learning ?


- ✚ - L'apprentissage profond est plus performant que les autres techniques **si la taille des données est importante**. Mais avec des données de petite taille, les algorithmes traditionnels d'apprentissage automatique sont préférables.
- ✚ - Lorsqu'il y a un **manque de compréhension du domaine** pour l'introspection des caractéristiques, les techniques d'apprentissage profond surpassent les autres car vous avez moins à vous soucier de l'ingénierie des caractéristiques.
- ✚ - L'apprentissage profond s'impose lorsqu'il s'agit de **problèmes complexes** tels que la classification d'images, le traitement du langage naturel et la reconnaissance vocale.

Machine Learning vs Deep Learning



On suppose qu'on doit calculer le prix de la maison et qu'on n'a pas de couche cachée. Le prix sera la simple somme des entrées pondérées. C'est un approche type apprentissage machine (Machine Learning) Par conséquent, ce qui rend le Deep Learning supérieur à l'apprentissage machine, c'est l'adjonction d'une couche cachée, qui donne de la puissance et de la flexibilité pour améliorer la qualité de l'estimation.

4. Exercice d'application



Étant donné que la fonction de sortie est une fonction sigmoïde, calculez les sorties intermédiaires h_1 et h_2 ainsi que la sortie finale $\hat{y}$.

Solution

1. **Formulation du problème** : Nous avons un réseau de neurones avec :

- Deux entrées $x_1=0,1$ et $x_2=0,3$
- Une sortie $Y=0,03$

Trois couches :

- Couche d'entrée
- Couche cachée h_1 et h_2
- Couche de sortie Y

2. **Poids et biais** :

Poids des connexions entre les entrées et les couches cachées :

1. $w_1=0,5$, $w_2 = 0,1$ (pour h_1)
2. $w_3=0,62$, $w_4=0,2$ (pour h_2)

Poids des connexions entre les couches cachées et la sortie :

3. $w_5 = -0,2$ (entre h_1 et la sortie)

4. $w_6 = 0,3$ (entre h_2 et la sortie)

Biais :

5. $b_1 = 0,4$ pour h_1

6. $b_2 = -0,1$ pour h_2

7. $b_3 = 1,83$ pour la sortie

- **Calcul des sorties des neurones cachés et de la sortie :**

- **Activation de la couche cachée :**

$$h_1 = f(w_1 \cdot x_1 + w_2 \cdot x_2 + b_1)$$

$$h_2 = f(w_3 \cdot x_1 + w_4 \cdot x_2 + b_1)$$

Où f est une fonction d'activation (fonction sigmoïde) :

- **Sortie :**

$$\hat{y} = f(w_5 \cdot h_1 + w_6 \cdot h_2 + b_3)$$

Où Y_{pred} est la sortie du réseau de neurones (predict).

- **Calcul de l'erreur (fonction de coût) :**

$$E = (Desired - predict)$$

1. **Calcul des activations des couches cachées :**

$$h_1 = f(w_1 \cdot x_1 + w_2 \cdot x_2 + b_1) = f(0,5 \times 0,1 + 0,1 \times 0,3 + 0,4)$$

$$h_1 = f(0,48) = \frac{1}{1 + e^{-0,48}} = \mathbf{0,617}$$

$$h_2 = f(w_3 \cdot x_1 + w_4 \cdot x_2 + b_2) = f(0,62 \times 0,1 + 0,2 \times 0,3 - 0,1)$$

$$h_2 = f(0,022) = \frac{1}{1 + e^{-0,022}} = \mathbf{0,505}$$

Calcul de la sortie prédite

$$\hat{y} = f(w_5 \cdot h_1 + w_6 \cdot h_2 + b_3) = f(-0,2 \times 0,617 + 0,3 \times 0,505 + 1,83)$$

$$\hat{y} = f(1,858) = \frac{1}{1+e^{-1,858}} = 0,865$$

Calcul de l'erreur (fonction de coût) :

$$E = \text{Desired} - \text{predict} = (0,03 - 0,865) = -0,83$$

5. Architecture d'un RNA

- Il existe différents types de réseaux neuronaux. On les catégorise le plus souvent en fonction de

L'architecture des couches intermédiaires.

- On appelle architecture la structure selon laquelle les neurones sont reliés entre eux.
- Plusieurs architectures de réseaux de neurones existent permettant de résoudre différents problèmes :

- ✓ Réseau de neurones “feedforward” (perceptron multicouche)
- ✓ Réseau de neurones convolutifs
- ✓ Réseau de neurones récurrents




Fig.10. Réseau de neurones “feedforward” (perceptron multicouche)




Fig.11. Réseau de neurones convolutifs




Fig.12. Réseau de neurone récurrents

Chapitre 4 : Réseaux Neuronaux Convolutifs (CNN)

4.1. Structure d'un CNN

- ✚ - Le réseau de neurone convolutif fonctionne en deux étapes :
- ✚ - l'extraction des caractéristiques et la classification des caractéristiques extraites.

Dans la première étape de nombreux filtres et couches de traitement sont appliquées aux images pour extraire l'information et ses caractéristiques. Quand c'est fait on passe à l'étape suivante de classification où les données sont triées en fonction de la variable cible du problème, un RNC typique ressemble à ça :

- Couche d'entrée
- Couche de convolution+ Fonction d'activation
- Couche de mise en commun (Pooling)

- Couche pleinement connectée (FL)

Un réseau de neurones convolutifs (CNN) est un type particulier de réseau de neurones conçu particulièrement pour traiter efficacement des images. Il est souvent utilisé pour des tâches de vision par ordinateur telles que la classification d'images, la détection d'objets et la segmentation sémantique.

Ce qui distingue les CNN, c'est leur capacité à apprendre automatiquement des hiérarchies de caractéristiques visuelles. Les couches initiales détectent des caractéristiques simples (comme les bords), puis les couches suivantes combinent ces caractéristiques pour identifier des motifs plus complexes, comme des formes ou des objets.

Les CNN sont fortement inspirés du fonctionnement du cortex visuel des vertébrés.

Leur architecture est conçue pour imiter certaines des fonctionnalités du système visuel biologique.

4.2. Convolution, filtres, pooling




Fig.13. Architecture du CNN

Le rôle de réseau de neurones convolutifs est de réduire les images sous une forme qui est plus facile à traiter, sans perdre les caractéristiques essentielles pour avoir une bonne capacité de prédiction.

Convolution

- La convolution est un outil mathématique simple qui est très largement utilisé pour le traitement d'image, ce qui explique que les réseaux de neurones à convolution soient particulièrement bien adaptés à la reconnaissance d'image.
- L'opération de convolution consiste à appliquer des filtres (noyaux de convolution) à l'image d'entrée. Ces filtres parcourent l'image, calculant la somme des produits entre les valeurs RGB des pixels et les coefficients du noyau pour détecter des caractéristiques visuelles.




Fig.13. Produit de convolution

Les Filtres

- Les filtres (ou noyaux de convolution) sont des matrices de poids qui glissent sur l'image en effectuant des opérations de convolution. Ces filtres agissent comme des détecteurs de caractéristiques.




Fig.14. Carte des caractéristique (FeatureMap)

Exemples de filtres




Fig.14. Différents types de filtres

Maxpooling

Couche de mise en commun Cette couche est appliquée après la couche de convolution.

Elle est utilisée pour réduire les dimensions de la cartographie. Par conséquent, elle réduit le nombre de paramètres à apprendre. Cela conserve néanmoins les informations ou caractéristiques importantes de l'image d'entrée.




Fig.15. Maxpooling

4.3. Exemple avec la base MNIST

Exemple d'un CNN pour la classification des images manuscrites de la base de données MNIST.




Fig.16. Classification des images manuscrites de la base de données MNIST.

Chapitre 5. Réseaux de neurones récurrents (Recursive Neural Networks - RvNN)

5.1. RNN et traitement de séquences

Les réseaux de neurones récurrents sont une catégorie de réseaux de neurones conçus pour traiter des données structurées sous forme hiérarchique, comme des arbres. Ils sont particulièrement utilisés dans le traitement du langage naturel (NLP), l'analyse syntaxique, et la compréhension sémantique.

Principe de fonctionnement :

- ✚ Contrairement aux réseaux de neurones récurrents (RNN), qui traitent des séquences linéaires (ex. : texte, séries temporelles), les RvNN traitent les entrées en suivant une structure arborescente. Chaque nœud de l'arbre est calculé à partir de ses sous-nœuds.

Structure typique :

- ✚ Chaque sous-arbre est représenté par un vecteur, calculé par un réseau de neurones partagé. Ce processus est récursif : on combine les vecteurs des enfants pour obtenir le vecteur du parent.

Exemple d'application :

- ✚ Analyse syntaxique des phrases (arbre syntaxique)
- ✚ Classification de sentiments (en analysant la structure grammaticale d'un texte)
- ✚ Représentation de graphes ou de structures en langage formel

Avantages :

- ✚ Capacité à capturer des relations hiérarchiques complexes
- ✚ Meilleure compréhension de la structure sémantique d'une phrase ou d'un document

Limites :

- ✚ Nécessite des données structurées (arbres syntaxiques, par exemple)
- ✚ Coût computationnel plus élevé que les RNN ou LSTM
- ✚ Moins flexible pour des séquences non hiérarchiques

Partie 3 : Traitement du Langage Naturel (NLP)

3.1. Introduction au NLP

Le traitement du langage naturel, ou NLP (Natural Language Processing), est un domaine de l'intelligence artificielle qui permet aux machines de comprendre, analyser, générer et interagir avec le langage humain. Il joue aujourd'hui un rôle central dans de nombreuses applications technologiques, que ce soit dans les assistants vocaux, les traducteurs automatiques ou encore les moteurs de recherche.

Comprendre les fondements du NLP, ses techniques et ses usages est essentiel pour quiconque s'intéresse à l'intelligence artificielle, à la linguistique computationnelle ou aux technologies du langage.

Le traitement du langage naturel (NLP) se structure autour de deux axes fondamentaux :

3.2. Sous-domaines : NLU, NLG

La compréhension du langage naturel (NLU – *Natural Language Understanding*), vise à analyser et interpréter le sens d'un texte.

La génération du langage naturel (NLG – *Natural Language Generation*), permet à une machine de produire un discours cohérent et compréhensible.

Le NLP se situe à l'intersection de trois disciplines majeures : l'informatique, la linguistique et l'intelligence artificielle. Il mobilise des approches issues de la linguistique computationnelle, ainsi que des techniques avancées d'apprentissage automatique (Machine Learning) et d'apprentissage profond (Deep Learning), afin de traiter et modéliser le langage humain de manière efficace.




Fig.16. Le positionnement du NLP dans l'écosystème de l'Intelligence Artificielle

3.3. Techniques de base du NLP (Tokenisation, lemmatisation, stemming)

Comprendre l'utilité du NLP dans notre quotidien

Dans un monde hyperconnecté, les interactions homme-machine deviennent de plus en plus naturelles grâce au NLP. Cette technologie permet, par exemple, aux chatbots de répondre aux demandes des utilisateurs de manière pertinente, aux outils de traduction automatique de proposer des résultats fluides, ou encore aux entreprises d'analyser les sentiments exprimés dans les réseaux sociaux pour affiner leur communication.

Le NLP rend ces échanges plus intuitifs et efficaces, en réduisant la barrière entre les données numériques et la langue humaine.

6. Les fondations techniques du NLP

Parmi les techniques de base, la tokenisation joue un rôle fondamental : elle consiste à découper un texte en unités significatives appelées "tokens" (mots, phrases, etc), facilitant ainsi leur traitement par un algorithme. Cette opération, qui semble simple en apparence, se heurte parfois à des subtilités linguistiques telles que la ponctuation, les contractions ou les expressions idiomatiques.

Autre pilier du NLP : la **lemmatisation**, qui consiste à ramener un mot à sa forme canonique (ou "lemme"). Par exemple, les mots "manger", "mangeons" et "mangé" peuvent tous être ramenés à "manger". Cette normalisation améliore considérablement la qualité de l'analyse textuelle et est particulièrement utile pour les systèmes de recherche ou les interfaces conversationnelles.

Il convient aussi de distinguer la lemmatisation de la **racinisation (Stemming)**, une méthode plus simple mais souvent moins précise, car elle tronque les mots sans tenir compte du contexte grammatical.

En traitement du langage naturel (NLP), l'on travaille principalement avec des données non structurées. Il est important de noter qu'environ 80 % des données produites par les entreprises ne sont pas structurées (Chiang, Catherine. 2018. *"In the Machine Learning Era, Unstructured Data Management is More Important Than Ever."* Igneous Blog, 31 juillet).

Parmi ces données textuelles non structurées, on peut citer les publications sur les réseaux sociaux, les articles de presse, les e-mails ou encore les avis de consommateurs. Pour pouvoir exploiter ces contenus, le NLP doit apprendre à modéliser la structure, la syntaxe et la grammaire du langage humain.

Grâce à ces traitements, il est possible d'extraire une grande variété d'informations : émotions exprimées, tonalité du message, organisation du discours, et bien plus encore.




Fig.17. Exemple d'extraction d'informations basée sur des techniques NLP

7. Des modèles de langage au cœur de la révolution NLP

Avec l'avènement de modèles de langage avancés tels que BERT, GPT ou T5, le NLP a connu un tournant majeur. Ces architectures permettent de comprendre le contexte global d'un texte et d'en produire de nouveaux avec un niveau de fluidité impressionnant. Elles reposent sur des techniques d'**apprentissage profond**, notamment les **transformers**, qui utilisent des mécanismes d'attention pour mieux capturer les relations entre mots, même lorsqu'ils sont éloignés dans une phrase.

Ces modèles sont aujourd'hui au cœur de nombreuses applications : génération automatique de texte, réponses aux questions, résumés automatiques, classification de documents, et bien d'autres. Toutefois, ils présentent également des défis, notamment en termes de biais algorithmiques, de coût computationnel et d'interprétabilité.

3.4. Représentation vectorielle : Word2Vec

Avant les transformers, d'autres approches ont pavé la voie. Le modèle **Word2Vec**, par exemple, a marqué un tournant dans la représentation vectorielle des mots. Il permet de projeter chaque mot dans un espace multidimensionnel en tenant compte de son contexte d'utilisation, révélant ainsi des liens sémantiques profonds (comme "roi" – "homme" + "femme" $\approx$ "reine"). Ces vecteurs ont ensuite été utilisés pour des tâches comme la classification, la détection de similarité, ou l'analyse de sentiments.

Les réseaux de neurones, dans leur ensemble, ont profondément transformé le traitement du langage. Leur capacité à apprendre des représentations complexes et contextuelles du texte a permis d'accroître la précision des systèmes intelligents dans divers secteurs : santé, finance, marketing, éducation, etc.

Vers des machines qui comprennent vraiment ?

Aujourd'hui, les systèmes NLP sont capables de résumer des articles, traduire des textes en plusieurs langues, détecter des émotions, ou même générer des dialogues cohérents. Bien que ces avancées soient impressionnantes, elles ne signifient pas encore que les machines "comprennent" le langage comme les humains. La compréhension demeure largement statistique, et des défis subsistent : gestion de l'ambiguïté, sens commun, ou encore prise en compte du contexte culturel.

Malgré tout, les progrès constants du domaine laissent entrevoir un futur où les interactions homme-machine seront toujours plus naturelles, intuitives et accessibles.

Partie 4 : Exercices et Applications**Série : 1****Exercice 1**

1. Quelle est la relation entre l'intelligence artificielle (IA) et l'apprentissage automatique (machine Learning) ?
2. Quelle est la principale différence entre l'apprentissage supervisé et l'apprentissage non supervisé ?
3. Quelles sont les différences clés entre la classification et la régression en apprentissage automatique ?
4. Pour un algorithme d'apprentissage automatique, est-il avantageux ou problématique d'avoir un grand volume de données ?
5. Quelles sont les différences majeures entre le machine Learning et le Deep Learning ?

Exercice 2

Dans cet exercice, vous explorerez plusieurs scénarios d'apprentissage automatique appliqués à des problèmes courants. Vous devrez déterminer le type de problème (classification, régression, association ou clustering) et identifier si l'apprentissage supervisé ou non supervisé.

1. Vous avez un ensemble de données contenant des informations sur les achats des clients dans un magasin, telles que le montant total des achats, le type de produits achetés, et le nombre d'achats. Vous souhaitez prédire le montant que chaque client dépensera lors de son prochain achat. Quel type de problème d'apprentissage automatique devez-vous résoudre ? De quel type de problème s'agit-il : classification, régression, ou clustering ?
2. Vous travaillez sur un projet visant à détecter les fraudes bancaires. Vous avez un jeu de données d'historique de transactions étiquetée (fraude) ou (non fraude). Vous souhaitez entraîner un modèle pour détecter les transactions suspectes (fraude) à partir de nouvelles données. Est-ce qu'il s'agit de l'apprentissage supervisé ou non supervisé ? De quel type de problème s'agit-il : classification, régression, ou clustering ?
3. Vous avez des données sur les habitudes d'achat de vos clients et vous souhaitez comprendre quels produits sont fréquemment achetés ensemble (par exemple, les clients qui achètent du pain achètent aussi souvent du beurre). Quel type d'algorithme utiliseriez-vous pour résoudre ce problème : régression, classification, ou association ? Pourquoi ?
4. Vous travaillez sur un projet d'analyse des sentiments dans des critiques de produits en ligne. Vous disposez d'un ensemble de données contenant des avis clients. Vous devez entraîner un modèle pour prédire l'étiquette de nouveaux avis. Est-ce qu'il s'agit de l'apprentissage supervisé ou non supervisé ? De quel type de problème s'agit-il : classification, régression, clustering ou association ?
5. Vous travaillez sur un projet de segmentation de marché pour une entreprise de marketing. Vous disposez de données comportementales des clients (comportement d'achat, historique de navigation, etc.), Est-ce qu'il s'agit de l'apprentissage supervisé ou non supervisé ? De quel type de problème s'agit-il : classification, régression, ou clustering ?

Exercice 3


Le tableau ci-dessous montre l'évolution du revenu disponible brut et de la consommation des ménages en euros dans un pays donné entre 1992 et 2001.

Année	Revenu	Consommation
1992	8000	7389.99
1993	9000	8169.65
1994	9500	8831.71
1995	9500	8652.84
1996	9800	8788.08
1997	11000	9616.21
1998	12000	10593.45
1999	13000	11186.11
2000	15000	12758.09
2001	16000	13869.62

Données
d'entraînement

Données test

Le graphique nuage de points est donné ci-dessous :



On cherche à expliquer la consommation des ménages (C) par le revenu (R).

1. Quelle est la nature de la relation entre la variable consommation des ménages et le revenu ?
2. Rédiger l'équation théorique du modèle qui relie la consommation des ménages au revenu.
3. Donner le modèle estimé du modèle qui relie la consommation des ménages au revenu.
4. Calculer la performance de ce modèle (le coefficient de détermination R^2).
5. Quelle est la valeur prédite de la consommation des ménages pour un individu ayant un revenu de 18 000 euros ?

Exercice 4

A. Soit un modèle linéaire simple

On donne les informations suivantes :

$$\sum XY = 184500, \sum Y^2 = 26350, \sum X^2 = 140000, \bar{Y} = 60, \bar{X} = 400, n = 7$$

1. Estimer les coefficients du modèle et écrire l'équation de la régression linéaire simple.
 2. Evaluer la qualité de cet ajustement ($R^2 = \frac{(\hat{b}_1)^2 [\sum X^2 - n\bar{x}^2]}{[\sum Y^2 - n\bar{y}^2]}$)
- B. Soit le modèle linéaire $y = b_0 + b_1 \cdot x + \varepsilon$

Où Y représente la quantité offerte de pommes et X le prix.

On donne les informations suivantes : $\bar{y} = 5$ et $\bar{x} = 3$. Après estimation, on a la droite de régression suivante : $\hat{y} = \hat{b}_0 + \hat{b}_1 X$. Connaissant le couple ($Y = 2.5$; $X = 2$) par lequel passe cette droite de régression.

1. Trouver $\hat{b}_0$ et $\hat{b}_1$.

Série : 2

Exercice 1 : perceptron simple

On vous donne un ensemble de données pour une tâche de classification binaire. Les données sont composées de trois caractéristiques (x_1, x_2 et x_3), l'objectif est de prédire la classe (0 ou 1) en fonction de ces caractéristiques. Voici un ensemble d'exemples :

x_1	x_2	x_3	$y_{réel}$
0	1	1	1
1	0	0	0
1	1	0	1

On donne des valeurs aléatoirement : $w_0 = 0,5$, $w_1 = 0$, $w_2 = 0$, $w_3 = 3$


La fonction d'activation considérée est une fonction échelon avec $\theta = 0$, le nombre des itérations est : $t_{max} = 3$ et le taux d'apprentissage $\alpha = 0.1$.

Appliquez la règle de mise à jour des poids pour entraîner les données.

Exercice 2


On considère un perceptron simple avec deux entrées, une sortie et une fonction d'activation échelon avec $\theta = 0$. Le problème de la porte logique "ET" consiste à prédire la sortie de la fonction logique "ET" en fonction de deux entrées binaires :

1. Déterminer les poids w_0, w_1, w_2 (avec w_0 et le biais) pour que le perceptron produise la sortie correcte en fonction des entrées.
2. Même question avec la fonction OU logique.
3. Est-il possible de déterminer les poids pour la fonction XOR en utilisant un perceptron simple ? Justifiez votre réponse.



Exercice 3

On considère le réseau de neurones suivant :



On utilise la fonction d'activation sigmoïde pour tous les neurones de la couche cachée et de la couche de sortie. Le réseau a trois neurones d'entrée $x = (0.5, 0.3, 0.7)^T$ et un seul neurone de sortie $y = 1$.

1. Estimez les valeurs des neurones de la couche cachée.
2. Quelle est la sortie estimée de ce réseau ?
3. Calculez l'erreur.

Exercice 4

Question de cours :

1. Qu'est-ce qu'un perceptron, et quel est son objectif initial ?
2. Comment calcule-t-on l'erreur dans un perceptron et quelle est la formule de mise à jour des poids ?
3. Pourquoi est-il important d'utiliser un taux d'apprentissage (α) dans un perceptron, et quelle est la valeur typique de ce taux ?
4. Quelles sont les principales différences entre l'apprentissage machine traditionnel et l'apprentissage profond ?
5. Quelles sont les fonctions des différentes couches dans un réseau de neurones (entrée, cachée, sortie) ?
6. En quoi un perceptron multicouche est-il plus puissant qu'un perceptron simple ?
7. Qu'est-ce qu'un réseau de neurones convolutifs (CNN) et dans quel type de tâches il est principalement utilisé ?
8. Décrivez brièvement l'architecture d'un réseau de neurones convolutifs. Quelles sont les fonctions spécifiques des couches de convolution et de pooling ?

Travaux pratiques

L'objectif principal de ces travaux pratiques n'est pas de résoudre intégralement les exercices proposés, qui peuvent s'avérer complexes pour les élèves ingénieur n'ayant pas une bonne maîtrise du langage Python, mais plutôt de se familiariser progressivement avec le code et de comprendre le déroulement de l'exécution des programmes.


Ces séances permettent aux apprenants de :

- Observer comment les algorithmes sont implémentés dans un environnement réel,
- Comprendre la logique des différentes étapes du traitement,
- Se sensibiliser aux outils de programmation et aux bibliothèques utilisées,
- Développer une approche intuitive de la modélisation et de l'analyse des données.

Ainsi, l'accent est mis sur l'initiation pratique et la compréhension générale du fonctionnement des scripts Python, plutôt que sur la performance ou la résolution complète du TP. Cela favorise une montée en compétence progressive, notamment pour les débutants en programmation.

Visualisation des résultats à l'aide de Jupyter Notebook

Dans le cadre des travaux pratiques, nous avons utilisé **Jupyter Notebook** comme environnement interactif pour l'affichage et l'analyse des résultats. Cet outil nous a permis de visualiser les données sous forme de graphiques, tableaux et courbes, facilitant ainsi l'interprétation des performances du modèle et l'ajustement des paramètres. Grâce à ses bibliothèques intégrées comme **Matplotlib**, **Seaborn** ou **Pandas**, la visualisation a été claire, structurée et adaptée aux besoins de l'analyse.



Partie 1

Régression linéaire pour la prédiction du profit d'une entreprise (Étude basée sur un jeu de données d'investissement).

Dans cette partie, nous allons appliquer une régression linéaire multiple dans le but de prédire le profit d'une entreprise en fonction de plusieurs variables d'investissement. Le jeu de données utilisé contient les informations financières de plusieurs entreprises, notamment :

- Dépenses en R&D (R&D Spend)
- Dépenses administratives (Administration)
- Dépenses marketing (Marketing Spend)
- Localisation géographique de l'entreprise (State)
- Profit réalisé (Profit)

L'objectif est de modéliser la relation entre ces variables indépendantes et la variable dépendante (le profit), afin de prédire les bénéfices futurs en fonction des choix d'investissement.

Ce type d'analyse est particulièrement utile en prise de décision stratégique, car il permet d'identifier les postes de dépenses les plus influents sur le rendement global de l'entreprise.

Extrait du code

```
[1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression

[15]: Dataset=pd.read_csv("50_Startups.csv")

[17]: Dataset.head()

[17]:
```

	R&D Spend	Administration	Marketing Spend	State	Profit
0	165349.20	136897.80	471784.10	New York	192261.83
1	162597.70	151377.59	443898.53	California	191792.06
2	153441.51	101145.55	407934.54	Florida	191050.39
3	144372.41	118671.85	383199.62	New York	182901.99
4	142107.34	91391.77	366168.42	Florida	166187.94

```
[19]: y=Dataset.iloc[:, -1].values
y

[19]: array([192261.83, 191792.06, 191050.39, 182901.99, 166187.94, 156991.12,
156122.51, 155752.6 , 152211.77, 149759.96, 146121.95, 144259.4 ,
141585.52, 134307.35, 132602.65, 129917.04, 126992.93, 125370.37,
124266.9 , 122776.86, 118474.03, 111313.02, 110352.25, 108733.99,
108552.04, 107404.34, 105733.54, 105008.31, 103282.38, 101004.64,
99937.59, 97483.56, 97427.84, 96778.92, 96712.8 , 96479.51,
90708.19, 89949.14, 81229.06, 81005.76, 78239.91, 77798.83,
71498.49, 69758.98, 65200.33, 64926.08, 49490.75, 42559.73,
35673.41, 14681.4 ])
```

```
[21]: x=Dataset.iloc[:, :-1]
x.head()

[21]:
```

	R&D Spend	Administration	Marketing Spend	State
0	165349.20	136897.80	471784.10	New York
1	162597.70	151377.59	443898.53	California
2	153441.51	101145.55	407934.54	Florida
3	144372.41	118671.85	383199.62	New York
4	142107.34	91391.77	366168.42	Florida

```
[33]: model=LinearRegression()
model.fit(x_train,y_train)

[33]:
```

LinearRegression ⓘ

```
LinearRegression()

[35]: y_pred=model.predict(x_test)
y_pred

[35]: array([103015.20159796, 132582.27760816, 132447.73845174, 71976.09851258,
178537.48221055, 116161.24230166, 67851.69209676, 98791.73374686,
113969.43533013, 167921.06569551])

[37]: from sklearn.metrics import r2_score
R2=r2_score(y_pred,y_test)
R2

[37]: 0.9293749209318047

[39]: from sklearn.metrics import mean_squared_error
mean_squared_error(y_test, y_pred)

[39]: 83507864.03750795
```

Partie 2

Classification des chiffres manuscrits à l'aide de la base de données MNIST Extrait de code

Dans cette partie, nous abordons la classification automatique des chiffres manuscrits en utilisant la célèbre base de données MNIST (Modified National Institute of Standards and Technology). Cette base contient 70 000 images en niveaux de gris de chiffres de 0 à 9, dont 60 000 images pour l'entraînement et 10 000 pour les tests. Chaque image est de taille 28×28 pixels.

L'objectif est d'entraîner un modèle d'apprentissage automatique (ou profond) capable d'identifier correctement le chiffre manuscrit représenté dans chaque image.

Voici un extrait de code illustrant l'approche utilisée pour cette tâche :

Extrait du code

Classification des chiffres manuscrites avec CNN

```
[1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import tensorflow as tf
from tensorflow import keras
from tensorflow.keras.datasets import mnist

[2]: ##Chargement du jeu de données MNIST (training set et test set)

[3]: (X_train, y_train), (X_test, y_test) = keras.datasets.mnist.load_data()

[4]: ##Affichage des dimensions de l'ensemble de données d'entraînement X_train


[5]: X_train.shape

[5]: (60000, 28, 28)

[11]: # Affichage de l'image de l'exemple d'index 2 de l'ensemble de données X_train avec une échelle de couleurs en niveaux de gris

[11]: plt.matshow(X_train[2], cmap='gray')
```

```
[11]: plt.matshow(X_train[2], cmap='gray')
[11]: <matplotlib.image.AxesImage at 0x277b309b620>
```



```
[14]: X_train = X_train.reshape(len(X_train),28,28,1) # rajouter une dimension à la fin
X_test = X_test.reshape(len(X_test),28,28,1)
print("X_train = ", X_train.shape)
print("X_test = ", X_test.shape)
print("y_train = ", y_train.shape)
print("y_test = ", y_test.shape)

X_train = (60000, 28, 28, 1)
X_test = (10000, 28, 28, 1)
y_train = (60000,)
y_test = (10000,)

[16]: ##Normalisation des données entre 0 et 1

[18]: X_train = X_train / 255
X_test = X_test / 255
```

```
[148]: from keras import Sequential
modelCNN = Sequential()
from keras.layers import Dense, Activation, Flatten, Conv2D, MaxPooling2D
#modelCNN.add(Conv2D(16, (3,3), activation='relu', input_shape=(28, 28, 1)))
modelCNN.add(Conv2D(20, (5,5), activation='relu', input_shape=(28, 28, 1)))
modelCNN.add(MaxPooling2D((4,4)))
modelCNN.add(Flatten())
modelCNN.add(Dense(40, activation='relu'))
modelCNN.add(Dense(10, activation='softmax'))
modelCNN.summary()
```

C:\Users\DELL\anaconda3\lib\site-packages\keras\src\layers\convolutional\base_conv.py:107: UserWarning: Do not pass an `input\_shape`/`input\_dim` argument to a layer. When using Sequential models, prefer using an `Input(shape)` object as the first layer in the model instead.
super().__init__(activity_regularizer=activity_regularizer, **kwargs)
Model: "sequential_6"

Layer (type)	Output Shape	Param #
conv2d_10 (Conv2D)	(None, 24, 24, 20)	520
max_pooling2d_10 (MaxPooling2D)	(None, 6, 6, 20)	0
flatten_6 (Flatten)	(None, 720)	0
dense_12 (Dense)	(None, 40)	28,840
dense_13 (Dense)	(None, 10)	410

```
[150]: modelCNN.layers[0].get_weights()[0].shape
[150]: (5, 5, 1, 20)

[154]: modelCNN.compile(optimizer='adam',
                      loss='sparse_categorical_crossentropy',
                      metrics=['accuracy'])

[156]: modelCNN_history = modelCNN.fit(X_train, y_train, epochs=100)

Epoch 1/100
1875/1875 — 12s 6ms/step - accuracy: 0.8745 - loss: 0.4384
Epoch 2/100
1875/1875 — 11s 6ms/step - accuracy: 0.9784 - loss: 0.0736
Epoch 3/100
1875/1875 — 10s 5ms/step - accuracy: 0.9837 - loss: 0.0531
Epoch 4/100
1875/1875 — 11s 6ms/step - accuracy: 0.9874 - loss: 0.0403
Epoch 5/100
1875/1875 — 11s 6ms/step - accuracy: 0.9905 - loss: 0.0297
Epoch 6/100
1875/1875 — 10s 5ms/step - accuracy: 0.9910 - loss: 0.0295
Epoch 7/100
1875/1875 — 11s 6ms/step - accuracy: 0.9921 - loss: 0.0254
Epoch 8/100
1875/1875 — 11s 6ms/step - accuracy: 0.9930 - loss: 0.0207
Epoch 9/100
1875/1875 — 11s 6ms/step - accuracy: 0.9948 - loss: 0.0165
```