


Introduction au Machine learning (ML)

Machine learning (ML)



Machine learning


- Sous-domaine de l'intelligence artificielle qui permet aux ordinateurs d'apprendre à partir de données sans être explicitement programmés.
- Devenu de plus en plus important dans divers domaines, et cela inclut la criminalistique.
- À mesure que les volumes de données numériques augmentent, il devient crucial de pouvoir extraire des informations utiles et des modèles significatifs à partir de ces données. Le machine learning offre des outils et des techniques puissants pour accomplir cette tâche.

Machine learning


- Exemple: un enfant qui apprend à reconnaître des animaux.
- Au lieu de programmer explicitement un ordinateur pour qu'il reconnaisse des objets ou effectue des tâches spécifiques, nous fournissons à l'ordinateur des données d'apprentissage.
- Ces données sont comme les images d'animaux pour notre enfant.
- L'ordinateur extrait des caractéristiques importantes à partir de ces données et ajuste ses paramètres internes pour s'améliorer progressivement dans sa tâche. Plus il voit de données, plus il devient compétent.
- Nous pouvons utiliser le machine learning pour analyser des preuves, détecter des schémas et résoudre des enquêtes de manière plus efficace.
- Le machine learning repose sur la capacité des ordinateurs à apprendre à partir des données, tout comme nous le faisons en tant qu'êtres humains.

Types d'apprentissage

Apprentissage supervisé



Apprentissage non supervisé



Types d'apprentissage:

- **Apprentissage Supervisé** : le modèle est "supervisé" par un ensemble de données d'entraînement étiqueté:
 - Chaque exemple d'entraînement est associé à une étiquette ou une réponse correcte.
 - Exemple: entraîner un modèle à reconnaître les chiffres manuscrits en lui fournissant des images de chiffres avec les étiquettes correspondantes (0, 1, 2, ...).
 - Le modèle apprend à faire des prédictions en se basant sur les exemples d'entraînement.
- **Apprentissage Non Supervisé** : ne repose pas sur des étiquettes:
 - Le modèle tente de découvrir des structures cachées ou des schémas dans les données sans avoir de réponse correcte préalable.
 - Exemple: la segmentation de clients en groupes similaires à des fins de marketing.
 - Le modèle identifiera automatiquement des clusters de clients similaires en fonction de leurs comportements d'achat, sans connaître à l'avance les catégories de clients.

Terminologie de Base

- **Ensembles de Données** : la matière première sur laquelle les modèles de machine learning sont formés.
- Par exemple, des informations sur les crimes, les suspects, les lieux, etc. pour une application en criminalistique.
- **Caractéristiques (Features)** : les variables ou les attributs des données que nous utilisons pour effectuer des prédictions.
- Par exemple: l'âge, la localisation, le moment de la journée, etc.
- **Modèles** : des algorithmes qui apprennent à partir des données pour effectuer des prédictions. Ils capturent les relations entre les caractéristiques et les résultats.
- Par exemple, un modèle pourrait être formé pour prédire la probabilité de succès d'un étudiant en fonction de son niveau, son environnement .

Exemple Concret

- On travaille sur un projet de santé publique où nous avons recueilli des informations sur les patients, leurs antécédents médicaux, leurs habitudes de vie, et les résultats de leurs analyses médicales. Nous voulons utiliser le machine learning pour aider à prédire le risque de développer le diabète de type 2.
- Ensembles de Données ?
- Caractéristiques ?
- Modèles ?

Processus de Machine Learning

- Collecte et Préparation des Données
- Choix et Formation du Modèle
- Évaluation et Ajustement du Modèle
- Utilisation du Modèle pour les Prédictions

Collecte et Préparation des Données

- **Collecte de Données** : la première étape de tout projet de machine learning.
 - Les données servent de matière première à nos modèles.
 - Elles peuvent provenir de diverses sources, telles que des bases de données existantes, des capteurs, des enquêtes, des médias sociaux, des vidéos de surveillance, des preuves physiques et bien d'autres.
 - Les données doivent être suffisamment représentatives du problème que nous cherchons à résoudre.
- **Qualité des Données** : L'une des règles d'or du machine learning est "Garbage in, garbage out" (Des données de mauvaise qualité entraînent des résultats de mauvaise qualité).
- **Préparation des Données** : pour qu'elles soient utilisables par nos modèles.
 - Cela implique la gestion des valeurs manquantes, la normalisation des données, la conversion de données catégorielles en format numérique, et bien d'autres.

Exploration et Préparation des Données

Objectifs

- Comprendre l'importance de l'EDA (Exploratory Data Analysis) dans le processus d'analyse de données et de préparation pour l'apprentissage automatique.
- Apprendre à faire l'EDA et la préparation des données.
- Maîtriser les techniques de visualisation pour révéler des informations essentielles dans les données.
- Préparer les données de manière appropriée pour l'entraînement de modèles d'apprentissage automatique.

L'importance de l'EDA :

- L'EDA est cruciale avant la préparation des données :
- L'EDA aide à découvrir des tendances, des modèles et des informations importantes dans les données.
- Elle permet d'identifier les erreurs, les valeurs aberrantes, les données manquantes et de prendre des décisions éclairées sur la manière de les gérer.
- Elle favorise une meilleure compréhension des données, ce qui est essentiel pour choisir les bonnes techniques de prétraitement et les modèles d'apprentissage automatique appropriés.

Exploration initiale des données

Objectif: Apprendre comment examiner les caractéristiques essentielles des données et comprendre la structure du jeu de données.

Visualisation des premières lignes

- Comprendre les premières données permet d'avoir une idée de ce à quoi ressemblent les données brutes.
- Permet de voir rapidement la qualité des données et s'il y a des problèmes évidents.
- On peut identifier des valeurs manquantes, des valeurs aberrantes, des données mal formatées, etc.
- L'aperçu des premières lignes facilite la compréhension des variables et des enregistrements dans le jeu de données, ce qui est essentiel pour la planification de l'analyse ultérieure.

Types de données

- Les types de données dans les colonnes sont essentiels pour comprendre comment les données sont stockées et interprétées.
- Ils influencent la manière dont vous pouvez effectuer des opérations sur ces colonnes.
- Les opérations mathématiques ne sont généralement possibles que sur des données numériques (int, float).
- Les opérations de chaînes de caractères (string) sont spécifiques aux données textuelles.
- Les dates et heures (datetime) nécessitent des opérations de traitement temporel spécifiques.

L'influence des types de données

- Les types de données déterminent les opérations que vous pouvez effectuer sur ces colonnes.
- Les opérations mathématiques telles que la somme, la moyenne, et la multiplication ne sont possibles que sur les colonnes numériques (int et float).
- Les colonnes de type string sont principalement destinées aux opérations de traitement du texte.
- Les colonnes datetime permettent des opérations de filtrage temporel, de regroupement par période, etc.

Valeurs manquantes (Identification)

- Il est essentiel de détecter les valeurs manquantes.
- Les valeurs manquantes peuvent biaiser les analyses et les modèles si elles ne sont pas correctement traitées.
- Elles peuvent indiquer des problèmes de collecte de données ou des erreurs dans les données.
- Identifier les valeurs manquantes est la première étape pour décider comment les gérer.

Gestion des valeurs manquantes

- **Suppression des lignes** : supprimer les lignes qui contiennent des valeurs manquantes si leur nombre est négligeable par rapport à la taille de l'ensemble de données.
- **Imputation** : remplacer les valeurs manquantes par des valeurs calculées, comme la moyenne, la médiane ou le mode pour les données numériques, ou une valeur catégorique pour les données catégoriques.
- **Conservation des valeurs manquantes** : Dans certains cas, il peut être approprié de conserver les valeurs manquantes pour des raisons spécifiques.
- Compter le nombre de valeurs manquantes par colonne est recommandé.
- Cela donne une vue d'ensemble rapide des colonnes qui ont des données manquantes.

Identifier les colonnes et leurs significations

- Il est essentiel de comprendre les colonnes et leurs significations dans un jeu de données :
 - Chaque colonne représente une variable ou une caractéristique de vos données.
 - Comprendre ce que chaque colonne représente est fondamental pour interpréter correctement les résultats de votre analyse.
 - Cela vous aide à sélectionner les bonnes colonnes pour vos analyses et à décider comment les traiter.
- Pour comprendre les colonnes, il est important d'examiner la documentation ou les métadonnées fournies avec le jeu de données :
 - La documentation peut contenir des descriptions détaillées de chaque colonne, y compris leur signification, leur unité de mesure, etc.
 - Les métadonnées peuvent également fournir des informations sur la source des données, les transformations préalables, et plus encore.

Nettoyage des données

Objectif: Apprendre comment identifier et traiter les problèmes courants dans les données, notamment les données manquantes, les doublons, et la conversion des types de données.

Traitement des données manquantes

- Les données manquantes peuvent entraîner des erreurs dans l'analyse et les modèles.
- On utilise les méthodes `isna()` ou `isnull()` pour identifier les données manquantes.
- Il existe différentes stratégies pour gérer les données manquantes :
- Supprimer les lignes ou les colonnes contenant des données manquantes.
- Imputer les valeurs manquantes par la moyenne, la médiane, le mode, ou d'autres méthodes pertinentes.
- La stratégie dépendra du contexte et de la quantité de données manquantes.

Gestions des doublons

- Les doublons sont des enregistrements répétés qui peuvent fausser les analyses et les résultats.
- Il est crucial de gérer les doublons dans un ensemble de données :
 - Ils peuvent entraîner une surestimation de la taille de l'échantillon, ce qui peut influencer les statistiques descriptives et les conclusions.
 - La présence de doublons peut également provoquer des biais dans les modèles d'apprentissage automatique.
- Il faut examiner attentivement les colonnes qui peuvent contenir des doublons, en particulier les identifiants uniques tels que les numéros d'identification.
- Les doublons peuvent parfois résulter d'erreurs de saisie ou de fusion de données.

Conversion des types de données

- Il peut être nécessaire de convertir les types de données dans un ensemble de données.
- Les types de données déterminent les opérations que vous pouvez effectuer sur les colonnes.
- Parfois, on doit changer les types de données pour réaliser certaines opérations.
- La conversion peut être nécessaire pour traiter correctement les données, notamment lorsque des colonnes numériques doivent être interprétées comme des colonnes catégoriques.
- Il faut être attentifs aux types de données lors de l'importation initiale des données et à comprendre les besoins de leur analyse pour décider des conversions nécessaires.

Pourquoi la conversion ?

- **Pour économiser de la mémoire** : La conversion en types de données plus spécifiques peut réduire l'utilisation de la mémoire.
- **Pour permettre des opérations spécifiques** : Parfois, des opérations ne sont possibles qu'avec certains types de données.
- **Pour faciliter l'analyse** : Convertir des données en types plus appropriés peut rendre l'analyse plus efficace et précise.

Statistiques descriptives

- Calculer différentes statistiques descriptives:
 - Moyenne (mean) : La somme des valeurs divisée par le nombre d'observations.
 - Médiane (median) : La valeur du milieu lorsque les données sont triées.
 - Écart type (standard deviation) : Mesure de la dispersion des données par rapport à la moyenne.
 - Minimum et maximum : Les valeurs les plus basses et les plus élevées dans les données.
 - Quartiles : Les valeurs qui divisent les données en quatre parties égales.

Visualisation univariée

- Explorer la distribution des variables individuelles dans un ensemble de données en utilisant des visualisations univariées.
- Cela permettra d'identifier les caractéristiques clés et les anomalies dans les données.
- La personnalisation des graphiques est importante pour les rendre compréhensibles et informatifs.
- Il faut choisir les visualisations appropriées en fonction du type de variable (continue ou catégorique) et des objectifs de leur analyse.
- On peut créer des histogrammes pour visualiser la distribution des variables continues

Diagrammes à barres

- Utiles pour représenter des variables discrètes (catégoriques):
 - Facilité d'interprétation : Les barres représentent clairement les catégories et leurs fréquences, ce qui facilite l'interprétation des données.
 - Comparaisons visuelles : de la fréquence ou la distribution des catégories, utile pour les analyses comparatives.
 - Personnalisation : pour rendre les graphiques informatifs et esthétiques.
 - Adaptabilité : fonctionnent pour des variables catégoriques avec un petit nombre de catégories, mais aussi pour des variables avec un nombre plus élevé de catégories.
 - Prise de décision : Utilisés pour prendre des décisions basées sur des données discrètes.

Visualisation bivariée et multivariée

- Utilisée pour comprendre les relations entre les variables.
- Étape cruciale dans l'analyse de données.
 - La détection de corrélations ou de dépendances entre les variables.
 - La capacité à identifier des tendances et des modèles complexes.
 - L'aide à la prise de décision informée en identifiant les facteurs qui influencent les résultats.
- Outils de visualisation à utiliser :
 - des graphiques de dispersion (scatter plots) pour les relations bivariées
 - des heatmaps ainsi que des pairplots pour les relations multivariées.

Préparation des Données

- Consiste à préparer et à organiser les données brutes de manière à ce qu'elles puissent être utilisées efficacement par les modèles d'apprentissage automatique.
- La réussite de tout projet d'IA repose en grande partie sur la qualité des données que nous utilisons.
- Les données brutes sont souvent désorganisées, incomplètes et peuvent contenir des erreurs.
- La préparation des données vise à résoudre ces problèmes en nettoyant, transformant et en préparant les données de manière à ce qu'elles puissent être exploitées par nos modèles.
- Une mauvaise préparation des données peut entraîner des résultats médiocres ou biaisés, tandis qu'une préparation rigoureuse peut conduire à des modèles plus performants et plus fiables.

Encodage des Variables Catégorielles

- Dans de nombreux ensembles de données, nous rencontrons des variables catégorielles
- Les algorithmes ne peuvent pas traiter ces variables directement car ils fonctionnent avec des nombres.
- Nous devons convertir ces variables catégorielles en une forme numérique que les modèles peuvent comprendre.
- Il existe deux principales techniques d'encodage des variables catégorielles que nous utilisons couramment :
 - l'encodage one-hot : créer de nouvelles colonnes binaires pour chaque catégorie.
 - l'encodage par étiquette : attribuer un nombre entier unique à chaque catégorie.

Normalisation ou Mise à l'Échelle des Variables Numériques

- Lorsque nous travaillons avec des variables numériques dans nos données, il est souvent nécessaire de normaliser ou de mettre à l'échelle ces variables.
- L'objectif est de garantir que toutes les variables ont des échelles comparables, ce qui est essentiel pour de nombreux algorithmes d'apprentissage automatique.
- Si les variables ont des échelles très différentes, certaines d'entre elles peuvent avoir un impact disproportionné sur le modèle, ce qui peut entraîner des performances médiocres.

Méthodes de normalisation

- Il existe deux méthodes de normalisation couramment utilisées : la normalisation min-max et la normalisation z-score:
 - **Normalisation Min-Max** : cette méthode redimensionne les valeurs pour qu'elles tombent dans une plage spécifiée, généralement de 0 à 1. Cependant, elle peut être sensible aux valeurs aberrantes.
 - **Normalisation Z-Score (Standardisation)** : Expliquez que cette méthode transforme les valeurs en écart-type par rapport à la moyenne. Elle a l'avantage de maintenir la distribution initiale, ce qui peut être important pour certains modèles.

Division des Données en Ensembles d'Entraînement et de Test

- Lorsque nous construisons des modèles ML, il est essentiel de savoir à quel point notre modèle est performant.
- Pour cela, nous devons tester notre modèle sur des données qu'il n'a jamais vues auparavant.
- C'est là qu'intervient la division des données en ensembles d'entraînement et de test.
- L'ensemble d'entraînement est utilisé pour former le modèle, tandis que l'ensemble de test est utilisé pour évaluer à quel point le modèle fonctionne bien sur de nouvelles données.
- Cela nous permet de mesurer la performance du modèle de manière objective.